


Qualitätssicherung, Testing und Usability

ICD-10 Suchsystem mit Ki-Unterstützung

Systemüberblick



- Deterministische ICD-Zuordnung
- LLM nur für Erklärung und Korrektur

Herausforderung

- Viele Synonyme (z.B Altersdiabetes)
- Tippfehler
- medizinische Begriffe komplex
- LLM darf keine falsche Klassifikation machen
- LLM Antwort nimmt viel Zeit in Anspruch

Testkonzept

Tests

Datenbank & Unit Tests

Suchpipeline & Fallbacks

Cache Lasttests &
Usability

Fokus

gesamte Pipeline testen

nicht nur das Endresultat

Methoden

- Pytest
- k6
- manuelle Tests
- usability tests

Durchführung der Tests

- Datenbank & Unit Tests
 - PyTest + SQL-Queries (ICD-Erkennung, Synonym-Mapping)
- Suchpipeline & Fallback
 - manuelle Pipeline-Tests (Tippfehler, Pgvector, LLM-Korrektur)
- Cache, Lasttests & Usability
 - k6 + Nutzertests (Antwortzeiten, Kontext-Chat)

> Tests wurden direkt auf dem implementierten System durchgeführt

Testergebnisse

“Altersdiabetes”

- Meilisearch

“Zuckerkrankheit”

- PgVector

“Diabts”

- LLM Korrektur

“xyzsa”

- kein Treffer

Performance Tests

Aufruf (LLM)	3-7 sek
Aufruf (Cache)	< 60 ms

60-100x schneller durch Cache

Lasttests

Virtuelle Benutzer	20
Dauer	60 sek
Requests	11'254
Fehler	0
p95	20ms

(Durchführung mit k6)

Usability Tests

Tests

- Testpersonen: 2-3 Personen
- keine medizinischen Vorkenntnisse
- Bsp. Aufgaben:
 - Was bedeutet E11.9
 - Suche Lumboischialgie
 - Folgefragen: “Darf ich sport machen?”

Resultate

- Suchfunktion verständlich
- Schnelle Informationsfindung
- zwei Verbesserungen gefunden:
 - klickbar wirkender Block
 - zu harter Fehlerpfad

Fazit

Ergebnisse

- System vorläufig getestet
- Pipeline funktioniert robust
- Deutliche performanceverbesserung durch Cache
- Kontext-Chat funktioniert zuverlässig
- Gute Benutzerfreundlichkeit

Ausblick

- Mehr Tests nötig; Langzeit Lasttests
- Parallelisierung testen